

# Regresión lineal

Dra. Ximena Gutierrez Vasques & Mtro. Víctor Mijangos

Facultad de Ingeniería

21 de enero, 2020



# Regresión lineal

Un ejemplo clásico del aprendizaje es la **regresión lineal** [1].

La idea general es encontrar una **función lineal** que describa el comportamiento de los datos. Es decir, dado unas variables de entrada  $X_1, X_2, \dots, X_d$ , queremos predecir un valor de salida  $Y$ . Por lo que debemos encontrar:

$$f(x) = y$$

tal que  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  y  $f$  lineal.



# Regresión lineal

Una función lineal es aquella que cumple:

$$f(\lambda x + x') = \lambda f(x) + f(x')$$

Y puede verse que las funciones lineales de  $\mathbb{R}^d$  a  $\mathbb{R}$  son de la forma:

$$f(x) = wx$$

Tal que  $w \in (\mathbb{R}^d)^*$ .

En la práctica se utiliza un parámetro de sesgo o bias, tal que las funciones son:

$$f(x) = wx + b$$

con  $w \in (\mathbb{R}^d)^*$ ,  $b \in \mathbb{R}$ .



# Regresión lineal

## Ejemplo

Supóngase que se tiene una lista de casas, tal que se conoce el número promedio de cuarto ( $X$ ) y el precio de la casa ( $Y$ ):

	$X$	$Y$
Casa 1	6	22.9
Casa 2	7.14	36.2
Casa 3	6.4	21.6
Casa 4	6.7	30.5
Casa 5	5.1	16.3
Casa 6	7.15	37.3
Casa 7	8.3	50
Caa 8	8.2	48



# Regresión lineal

Pueden plantearse la preguntas:

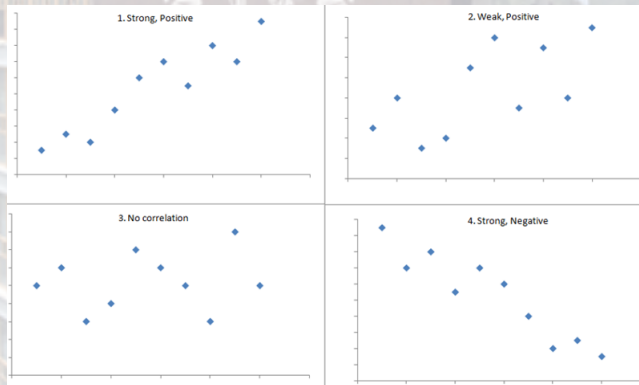
- ▶ ¿Existe una correlación (lineal) entre las variables  $X$  e  $Y$ .
- ▶ Si existe ¿cómo se comporta esta correlación?

A partir de la regresión lineal, podemos estimar la correlación que existe entre una y otra variable.



## Regresión lineal y correlación lineal

Una correlación estima la dependencia entre dos variables aleatorias. Una alta correlación asegura que la regresión lineal se acople a los datos adecuadamente.





## Residuos en regresión lineal

El objetivo es entonces predecir el valor de salida  $y$  de un valor de entrada  $x$ . Podemos estimar que el valor  $y$  es [1]:

$$y = wx + b + \epsilon_y$$

Aquí,  $\epsilon_y$  es un residuo.



## Residuos en regresión lineal

Despejando la función anterior, obtenemos que los residuos se calculan como:

$$\epsilon_y = y - wx + b$$

O bien, como:

$$\epsilon_y = y - f(x)$$





## Función de riesgo en regresión

Para garantizar que la regresión es adecuada, se busca que la suma de los residuos sea pequeña. Surgen dos aproximaciones:

- **Least-absolute value (LAV):**

$$R(f) = \sum_S |y - f(x)|$$

- **Least-squares:**

$$R(f) = \sum_S (y - f(x))^2$$

El método de least-squares representa mayor sencillez para resolverse.



## Regresión lineal como problema de aprendizaje

Hasta ahora contamos con los siguientes elementos:

1. Un conjunto de datos supervisados  $\mathcal{S} = \{(x, y) : x \in \mathbb{R}^d, y \in \mathbb{R}\}$  (se espera que exista una correlación lineal entre  $X$  y  $Y$ ).
2. Una función que define la ML:

$$f(x) = wx + b$$

tal que  $w \in \mathbb{R}^d$  y  $b \in \mathbb{R}$  son los parámetros a aprender.

3. Una función de riesgo:

$$R(f) = \frac{1}{2} \sum_{\mathcal{S}} (y - f(x))^2$$

(El factor  $\frac{1}{2}$  ayuda a simplificar la derivación).



## Regresión lineal como problema de aprendizaje

El objetivo es encontrar una función  $\hat{f}$  (dependiente de  $w$  y  $b$ ) que minimice la función de riesgo. Asumimos que  $R$  es convexa, entonces buscamos su punto de inflexión tal que:

$$\nabla_w R(f) = 0$$

De aquí que:

$$\nabla_w \frac{1}{2} \sum_S (y - f(x))^2 = 0$$

$$\nabla_w \frac{1}{2} \|Y - Xw\|^2 = 0$$

$$X^T Y - X^T X w = 0$$

$$(X^T X)^{-1} X^T Y = w$$



## Regresión lineal como problema de aprendizaje

Se ha incorporado el bias al vector  $w$  ( $[w; b]$ ).  $Y$  es el vector de valores esperados y  $X$  la matriz cuyos renglones son los ejemplos.

Tenemos, entonces que:

$$\arg \min_w \frac{1}{2} \|Y - Xw\|^2 = (X^T X)^{-1} X^T Y$$



## Regresión como modelo paramétrico

La regresión lineal es un **modelo paramétrico**, en tanto asume propiedades de la distribución de los datos.

Desde una perspectiva probabilística, la regresión lineal busca estimar  $\mathbf{p}(\mathbf{y})$  asumiendo que [1]:

$$y \sim N(f(x), 1)$$

Es decir, asume una distribución normal.



## Distribución normal

En este sentido, la función de probabilidad depende de dos parámetros: **media** y **varianza**. Esta última se asume igual a 1, tal que:

$$p(y) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}(y - f(x))^2\right]$$

El objetivo entonces es estimar la media  $f(x)$  con respecto a los datos  $X$  de entrada.





## Relación con la entropía

Dada la función de probabilidad (que depende de  $f$ , ergo de  $w$ ) se busca minimizar la entropía:

$$R(p) = - \sum_y \ln p(y)$$

De aquí:

$$\begin{aligned} \arg \min R(p) &= \arg \min - \sum_y \ln \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{1}{2}(y - f(x))^2\right] \\ &= \arg \min - \sum_y \left[ \ln \frac{1}{\sqrt{2\pi}} \right] - \frac{1}{2}(y - f(x))^2 \\ &= \arg \min \frac{1}{2} \sum_S (y - f(x))^2 \end{aligned}$$



## References



John Fox.

*Applied regression analysis and generalized linear models.*

Sage Publications, 2015.



The End

