

# Radial basis networks

Dra. Ximena Gutierrez Vasques & Mtro. Víctor Mijangos

Facultad de Ingeniería

13-17 de enero, 2020




## Datos no linealmente separables

La limitación del perceptrón es encontrarse con conjuntos de datos no convexos.

Las redes multicapa puede lidiar con este problema proyectando los datos a otro espacio.

Pero si en lugar de buscar fronteras de decisión lineales, buscamos que sean **radiales**.



## Interpolación y RBF

**Problema de interpolación:** Dado un conjunto  $\{x : x \in \mathbf{R}^d\}$  y un conjunto finito de reales  $\{f_i : f_i \in \mathbf{R}, i = 1, \dots, N\}$ , el problema de interpolación consiste en escoger una función  $\psi : \mathbf{R}^d \rightarrow \mathbf{R}$  que cumpla la condición:

$$\psi(x) = f_i$$

El método de **Radial Basis Function** [1] construye un espacio lineal que depende de la posición relativa de los puntos de acuerdo a una métrica. Así:

$$\psi(x) = \sum_{j=1}^N \lambda_j \phi(\|x - c_j\|)$$

Donde  $c_j \in \mathbf{R}^d$  son los centros de la basis function.



## Radial Basis Function

La **función radial** depende de la **norma** en el espacio  $\| \cdot \|$  y de **centros radiales**  $c_j$ .

- ▶ Entre más **cercano** esté un punto del centro  $c_j$  **mayor** será el valor de  $\psi$ .
- ▶ Entre más **lejano** esté un punto del centro  $c_j$  **menor** será el valor de  $\psi$ .

Así, podemos considerar una clasificación en términos de esta función. En el caso **binario**, podemos definirla como:

$$f(x) = \begin{cases} 1 & \text{si } \psi(x) > b \\ 0 & \text{si } \psi(x) \leq b \end{cases}$$



## Radial Basis Function

En la función radial,  $\lambda$  es una serie de parámetros. La función  $\phi(||x - c_j||)$  puede determinarse como **una función de probabilidad**:

$$p(x \in N(c_j)) = \exp\left\{-\frac{1}{2}||x - c_j||^2\right\}$$

Esta función describe una especie de distribución **normal**, donde  $c_j$  es la media.



## Radial Basis Network

Ahora, bien, bajo esta perspectiva probabilística, la función radial queda determinada como sigue:

$$\psi(x) = \sum_{j=1}^k \lambda_j \exp\left\{-\frac{1}{2} \|x - c_j\|^2\right\}$$

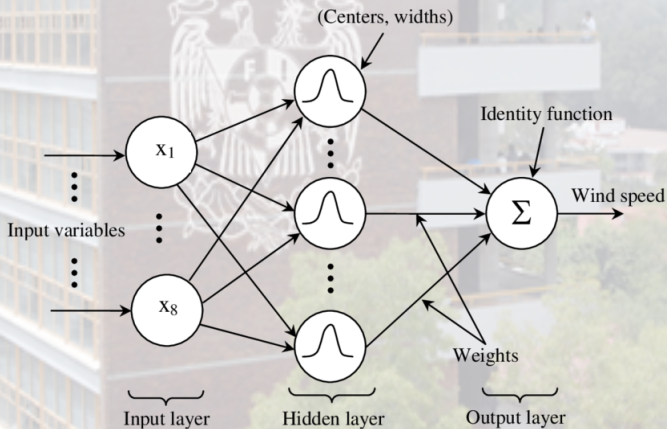
Sustituyendo  $\lambda_j$  por  $w_j$  y junto con la función de decisión que hemos definido, esta función puede verse como una red con una capa oculta. A este tipo de redes se les conoce como **Radial Basis Networks** (RBN).





## Radial Basis Network

La red consta de una capa oculta **probabilística**, mientras que la capa de salida puede verse como un **perceptrón**.



## Estimación de parámetros

Las RBN son capaces de solucionar problemas no linealmente separables, como el problema XOR.

Sin embargo, a diferencia de las redes FeedForward, la capa oculta determina  $k$  distribuciones de probabilidad.

Entonces, además de estimar los pesos de las conexiones (en la salida) se deben estimar los parámetros de las distribuciones.





## Capa oculta

La capa oculta representa el mayor problema. Podemos pensarla **independientemente** de la capa de salida.

Así, el problema se vuelve en estimar los parámetros  $C = \{c_1, \dots, c_k\}$  que se acoplen a la distribución.

Para esto, es común utilizar un algoritmo de **clustering**. Específicamente *k*-means.



## Función de riesgo en capa oculta

Dado que la función en la capa oculta está definida como una distribución, podemos ver que la función a minimizar está dada por:

$$\begin{aligned}\hat{C} &= \arg \min_C -\frac{1}{N} \sum_x \sum_{j=1}^k \ln \phi(\|x - c_j\|) \\ &= \arg \min_C -\frac{1}{N} \sum_x \sum_{j=1}^k \ln \exp\left\{-\frac{1}{2}\|x - c_j\|^2\right\} \\ &= \arg \min_C \frac{1}{2N} \sum_x \sum_{j=1}^k \|x - c_j\|^2\end{aligned}$$



## Estimación de parámetros en la capa oculta

El problema así definido se puede interpretar como **minimización de la varianza** para cada distribución.

Tenemos que:

$$\nabla_{c_j} \frac{1}{2N} \sum_x \sum_{j=1}^k ||x - c_j||^2 = \frac{1}{N} \sum_x x - c_j$$

E igualand a cero el gradiente obtenemos que:

$$c_j = \frac{1}{N} \sum_x x$$

Esto es **la media empírica**. Sin embargo, ya que existen varias distribuciones, esta media es únicamente entre los  $x$  más cercanos a  $c_j$ .



## k means

Este problema de minimización puede resolverse por medio del algoritmo de  $k$ -means.

Si bien  $k$ -means se ve como un algoritmo de clustering, los centroides de este algoritmo definen una media de la **distribución de un cluster**.



## Algoritmo de k means

**Inicialización** : Se inicializan los centroides  $C = \{c_1, c_2, \dots, c_k\}$  a leatoriamente.

**Inducción** : Para cada ejemplo  $x$  se calcula:

$$d(x, c_j) = ||x - c_j||$$

Se estiman los clusters como:

$$clust(x) = \arg \min_j d(x, c_j)$$

Se mueven los centroides con respecto a la siguiente regla:

$$c_j \leftarrow \frac{1}{N} \sum_{clust(x)=j} x$$

**Finalización** : Se finaliza cuando no se hagan nuevas asignaciones de los centroides.



## Obtención de la capa oculta

La capa oculta de la RBN estará definida por los parámetros  $\hat{C} = \{c_1, \dots, c_k\}$  estimados por el algoritmo de  $k$ -means.

La capa oculta en esta red está definida por:

$$h_j = \exp\left\{\frac{1}{2}\|x - c_j\|^2\right\}$$

Es decir, depende de  $c_j$  y se puede interpretar como una función probabilística.

La probabilidad de un dato dependerá de la cercanía a  $c_j$ . Así el radio de  $c_j$  define el valor de la unidad oculta.





## Cálculo de la capa de salida

Para obtener los valores de capa de salida se determina la función:

$$\psi(x) = \sum_{i=1}^k w_i h_i$$

donde  $w_i$  son pesos en la capa de salida. Así, puede definirse la función de clasificación como:

$$f(x) = \begin{cases} 1 & \text{si } \psi(x) > 0 \\ 0 & \text{si } \psi(x) \leq 0 \end{cases}$$



## References

-  **David S Broomhead and David Lowe.**  
Radial basis functions, multi-variable functional interpolation and adaptive networks.  
Technical report, Royal Signals and Radar Establishment Malvern (United Kingdom), 1988.



The End

